Обзор статьи

Characterization of Large Language Model Development in the Datacenter

Характеризация разработки больших языковых моделей в дата-центре

Студенты АлтГТУ, группа 8 ПИ-51
Бельш А.Е.
Воробьев К.В.
Мэн Ч.
Ошурков Н.А.

2026 г.

Анализ рабочих нагрузок LLM в дата-центре Acme

Крупные языковые модели достигли впечатляющих результатов, но их разработка на больших GPU-кластерах сопряжена с особыми проблемами: частые сбои, сложные стратегии параллелизации и несбалансированное использование ресурсов.
В этой работе представлено шестимесячное эмпирическое исследование трассировок из Acme (кластеры Seren и Kalos, всего 4704 GPU A100) и разработаны системные решения для повышения надежности и эффективности.

Контекст и мотивация

Большие языковые модели (LLM) требуют миллиардов параметров и огромных объёмов данных, поэтому компании создают крупные GPU-кластеры для их обучения.
Однако многие выводы из прежних анализов глубокого обучения (DL) неприменимы к LLM из-за:

- новой парадигмы: масштабное самоконтролируемое предварительное обучение (self-supervised pretraining);
- унифицированной архитектуры: все LLM используют Transformers;
- специализированного программного стека: Deepspeed, Megatron, Alpa и др.

Контекст и мотивация

Большие языковые модели (LLM) требуют миллиардов параметров и огромных объёмов данных, поэтому компании создают крупные GPU-кластеры для их обучения.
Однако многие выводы из прежних анализов глубокого обучения (DL) неприменимы к LLM из-за:

- новой парадигмы: масштабное самоконтролируемое предварительное обучение (self-supervised pretraining);
- унифицированной архитектуры: все LLM используют Transformers;
- специализированного программного стека: Deepspeed, Megatron, Alpa и др.

Методология: трассировки Acme

Анализ основан на данных за 6 месяцев (март–август 2023) из двух кластеров для LLM:

- **Seren:** 2288 GPU A100;
- **Kalos:** 2416 GPU A100.

Источники данных:

- журналы планировщика задач;
- мониторинг инфраструктуры (Prometheus, NVIDIA DCGM);
- журналы выполнения и профилирование.

Трассировки охватывают сотни тысяч заданий CPU/GPU и детальные метрики оборудования.

Ключевые наблюдения — время выполнения и задержки

- **Короткая продолжительность заданий:** Средняя длительность заданий LLM в 2,7–12,8 раз короче, чем в ранее опубликованных DL-трассировках. Это связано с множеством краткосрочных задач, таких как оценка и тюнинг.
- **Несправедливая задержка в очереди:** Короткие оценочные задания испытывают наибольшие задержки в очереди, потому что ресурсы преимущественно резервируются для долгих предобучающих задач (pretraining).

Ключевые наблюдения — использование ресурсов

Несбалансированное потребление:

- Предобучение (pretraining) — 3.2% заданий, но потребляет 94.0% GPU-времени (Kalos);
- Оценка (evaluation) — 92.9% заданий, но использует только 0.8% ресурсов.

Недоиспользование сопутствующих ресурсов:

- CPU, хост-память и сеть часто не загружены;
- GPU и память GPU показывают высокие медианные значения:
  - Kalos: GPU-память медиана 75% (60 ГБ), GPU-использование 99%

Проблемы в оценочных заданиях

Профилирование показало значительное время ожидания и простоя GPU в оценочных конвейерах:

- Пример: HumanEval тратит 29.5% времени на загрузку модели и предобработку данных;
- 19.0% времени уходит на проверку корректности синтезированных программ;
- Лишь около 50% времени используется непосредственно для вывода на GPU.

Следствие: это удлиняет очереди при массовой оценке и увеличивает задержки выполнения заданий.

Системные решения Acme — обзор

На основе наблюдений разработаны две ключевые системы:

1. **Отказоустойчивое предварительное обучение:** для диагностики сбоев и автоматического восстановления.
2. **Раздельное планирование оценки:** для ускорения обратной связи и сокращения простоя GPU.

Отказоустойчивое предварительное обучение

- Частые асинхронные контрольные точки (checkpoints) для быстрого восстановления.
- Диагностика корневых причин с помощью эвристик и LLM-помощника.
- Инструменты для обнаружения неисправных узлов и автоматического перезапуска из корректной контрольной точки.

Эффект: ускорение проверки восстановлений в 3.6–58.7 раза и значительное сокращение ручного вмешательства.

Раздельное планирование оценки и выводы

Развязка извлечения модели:

- Избегает конфликтов при удалённой загрузке модели за счёт отдельной фазы извлечения.

Развязка вычисления метрик:

- Минимизирует простой GPU, параллелит вычисление метрик и балансирует нагрузку по предзнаниям и наборам данных.

Практический эффект:

- Сокращение времени оценки до 1.8x.
- Повышена своевременная обратная связь по качеству модели.

Ресурсы: трассировки и код опубликованы на `https://github.com/InternLM/AcmeTrace`.

Конвейер разработки LLM

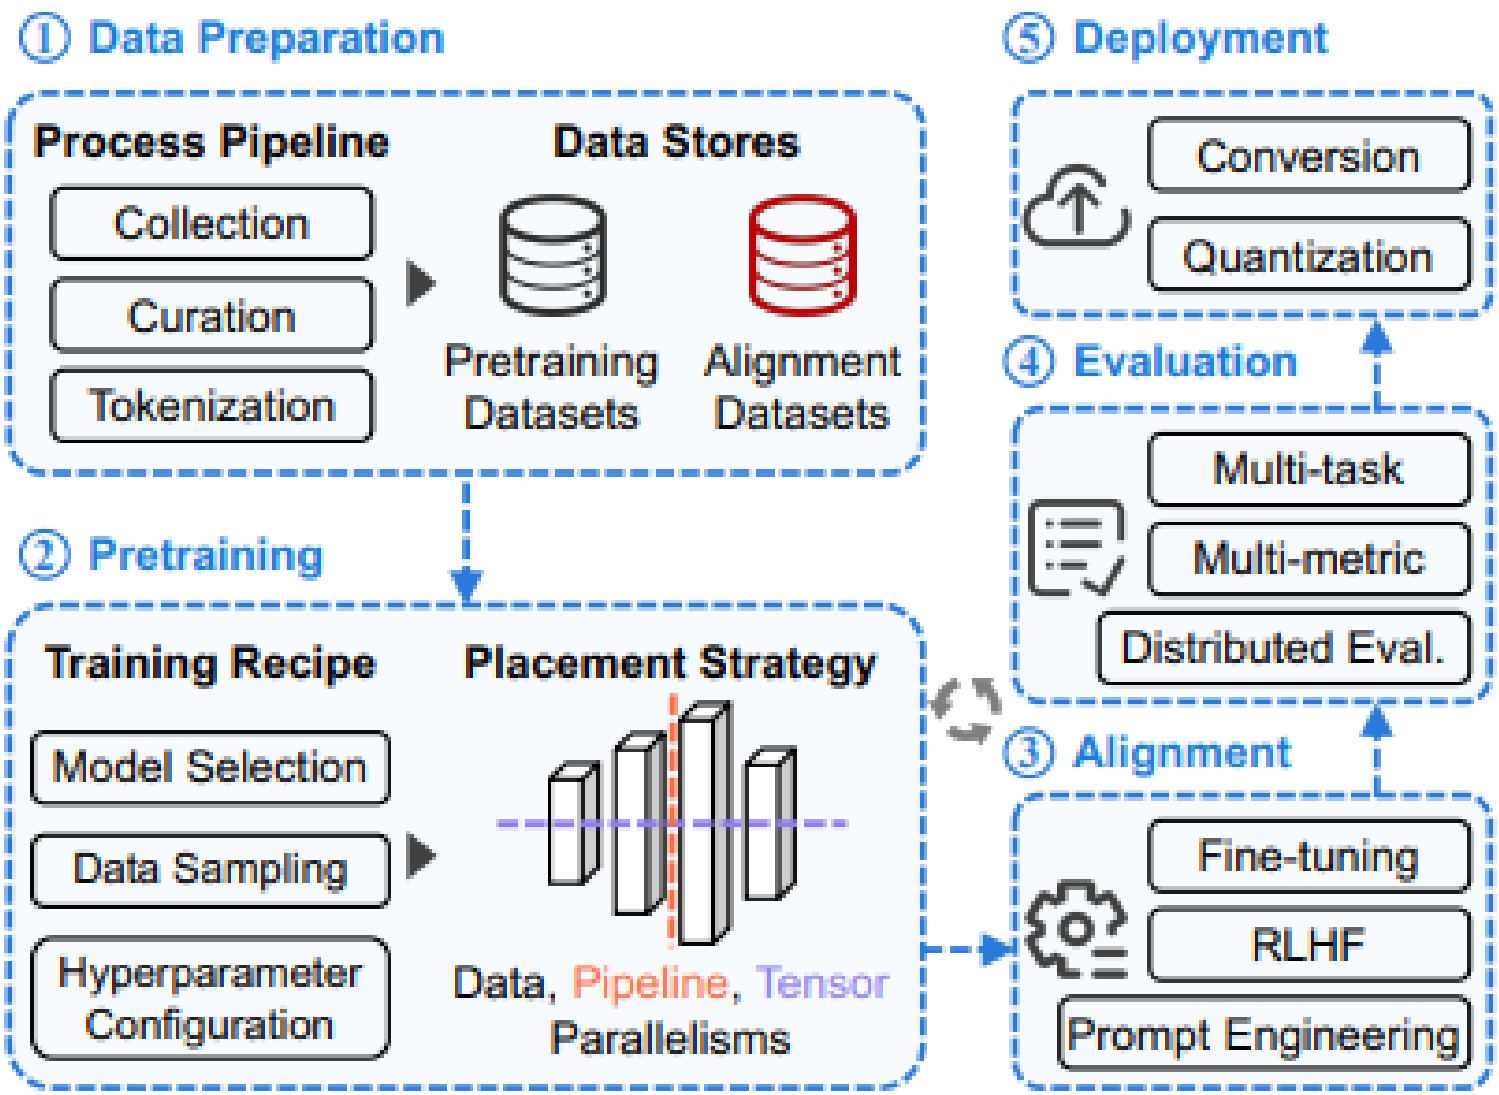

Раздел 3: Характеристика рабочей нагрузки разработки LLM

- **Цель:** Сравнить LLM с предыдущими DL нагрузками и выявить особенности использования ресурсов и сбоев.
- **Методология:** Анализ 6-месячных логов (март-август 2023) из датацентров Seren и Kalos (всего 4704 GPU A100).
- **Типы работ:** Претренинг (Pretraining), дообучение (Fine-tuning), выравнивание (Alignment), оценка (Evaluation), подготовка данных (Data preparation).

3.2 Характеристики рабочей нагрузки

- **Длительность работ:** В среднем 2.7–12.8x **короче**, чем в предыдущих DL трейсах (из-за большого числа коротких задач оценки).
- **Задержка в очереди:**
  - Вопреки прошлым выводам, **крупные** задачи (претренинг) имеют **меньшую** задержку (медиана 28 сек в Kalos).
  - **Короткие** задачи оценки ждут дольше всех (медиана 7.8 мин в Kalos), так как используют только остаточные ресурсы.
- **Распределение потребления ресурсов (Kalos):**
  - Претренинг: 3.2% работ, но **94.0% GPU-времени**.
  - Оценка: 92.9% работ, но лишь **0.8% GPU-времени**.

3.3 Структура использования ресурсов

- **Высокая утилизация GPU:**
  - Память GPU (медиана 75%, 60 ГБ) и вычислительная способность (медиана 99% в Kalos) загружены сильно.
  - Это намного выше, чем в старых DL трейсах (PAI: 10% и 4%).
  - Вывод: LLM интенсивны к вычислениям и памяти; методы разделения GPU (*GPU sharing*) неэффективны.
- **Недоиспользование сопутствующих ресурсов:**
  - CPU, хост-память и сеть загружены слабо (CPU в Kalos в среднем на 20%).
  - Основной бутылочное горлышко — операции ввода-вывода при подготовке данных.

3.3 Длительный простой GPU при оценке

- Профилирование задачи `HumanEval` показало:
  - **29.5% времени:** Загрузка модели и предобработка данных (CPU/диск).
  - **19.0% времени:** Тестирование синтезированных программ (CPU).
  - **Только 51.5% времени:** Непосредственно инференс на GPU.
- **Проблема:** GPU простаивает почти половину времени выполнения задачи оценки, что снижает эффективность и увеличивает задержки в очереди.

3.4 Анализ сбоев

- **Типы ошибок:**
  - **На старте (быстрое завершение):** Ошибки конфигурации, некорректные пути к данным (в основном для коротких задач).
  - **Во время выполнения:** Сбои оборудования (GPU, InfiniBand, диск), характерные для долгих задач претренинга.
- **Влияние:** Сбои инфраструктуры сильно снижают эффективность претренинга, требуя быстрой диагностики и восстановления.

На основе анализа проблем (сбои, задержки оценки) разработаны две системы:

1. **Fault-Tolerant Pretraining (Отказоустойчивый претренинг)**
2. **Decoupled Scheduling for Evaluation (Декомпозированное планирование для оценки)**

Обе интегрированы в фреймворк `InternEvo`.

4.1 Fault-Tolerant Pretraining: Компоненты

- **Асинхронное чекпойнтинг:**
  - Ускоряет сохранение состояния модели в **3.6–58.7x** раз по сравнению с синхронным подходом.
  - Позволяет делать чекпойнты часто, не блокируя обучение.
- **Диагностика с помощью LLM:**
  - Комбинация эвристических правил и LLM для анализа логов.
  - LLM помогает классифицировать и находить первопричины редких или сложных ошибок.
- **Холлистический детектор:**
  - Набор инструментов для точного определения неисправного узла (GPU, сеть, память).
  - Автоматический перезапуск задачи с последнего корректного чекпойнта.
- **Результат:** Снижение необходимости ручного вмешательства и простоев.

4.2 Decoupled Scheduling for Evaluation

- **Проблема:** Длительные простои GPU из-за загрузки модели с удаленного хранилища и CPU-вычислений метрик.

Решения:

- **Декомпозиция загрузки модели:** Кэширование моделей локально на узлах, чтобы избежать повторной загрузки по сети для каждой задачи.
- **Декомпозиция вычисления метрик:** Вынос тестов синтезированных программ (CPU-bound) на отдельные пулы ресурсов, освобождая GPU для инференса.
- **Балансировка на основе знаний о датасетах:** Использование prior knowledge (размер датасета, сложность) для равномерного распределения подзадач по GPU.

Результат: Сокращение общего времени выполнения оценки (*makespan*) до **1.8x**.

beamer [T2A]fontenc [utf8]inputenc [russian]babel []beamerthemeMadrid []beamercolorthemeseahorse

Масштаб исследования

- Дата-центр Acme: 4 704 GPU A100
- 1.09 млн LLM-задач за 6 месяцев
- Среднее число GPU на задачу - 6.3
- Модели от 7B до 123B параметров
- Анализ этапа обучения (serving вынесен в отдельный кластер)

Важно: исследование основано на промышленной эксплуатации, а не на лабораторном эксперименте.

Выявленные системные проблемы

- Падение throughput в 2–3 раза из-за Garbage Collection
- До 30% времени шага занимала функция `list_traverse`
- Утечка памяти в PyTorch Dataloader -> сбой в среднем через 27 часов
- Низкая утилизация GPU в MoE на 1024 GPU
- Узкое место - all-to-all сетевые коммуникации

Вывод: LLM-нагрузки создают новые инфраструктурные риски.